

Ejercicio 01 · Dataset público y SVM reproducible

INF-8239 · Maestría en Ciencia de Datos II · Entrega individual

Repositorio: <https://github.com/DAMB18/SVM-con-pipeline>

Esta entrega integra dos desarrollos: LAB01 (dataset de cáncer de mama, realizado previamente) y LAB02 (dataset público de fuga de clientes, desarrollado en esta práctica). Ambos comparan un baseline (Dummy) contra un SVM sobre la misma partición train/test dentro de un Pipeline de scikit-learn.

Identificación de los datasets

LAB01 — Breast Cancer Wisconsin (sklearn)

- **Fuente:** sklearn.datasets.load_breast_cancer (dataset de referencia incluido en scikit-learn; originalmente del UCI ML Repository).
- **Unidad de análisis:** muestra de biopsia de tejido mamario.
- **Target:** diagnóstico binario (maligno / benigno).
- **Notebook:** notebooks/01_svm_giada.ipynb.


LAB02 — Iranian Churn Dataset (UCI)

- **Ficha:** archive.ics.uci.edu/dataset/563/iranian+churn+dataset
- **Licencia:** CC BY 4.0. Descarga pública sin autenticación.
- **Unidad de análisis:** cliente individual de una empresa de telecomunicaciones.
- **Target:** Churn, binario (1 = cancela el servicio, 0 = permanece); ~15.7% clase positiva.
- **Notebook:** notebooks/02_churn_svm.ipynb. Procedencia, candidatos comparados, criterios de aceptación y diccionario completo en docs/ficha_dataset.md y docs/diccionario_datos.md.

Tabla principal de resultados

Desarrollo	Modelo	F1 macro	Notas
LAB01 – Breast Cancer	Dummy (most_frequent)	0.38	baseline
LAB01 – Breast Cancer	SVM (rbf, C=1)	0.98	antes de GridSearchCV
LAB01 – Breast Cancer	SVM + GridSearchCV (mejor)	0.974 (CV)	C=10, gamma=0.01
LAB02 – Churn	Dummy (most_frequent)	0.457	baseline
LAB02 – Churn	SVM (rbf, C=1, gamma=scale)	0.841	recall clase churn = 0.58

Figuras



Matriz de confusión del SVM de LAB02 sobre el conjunto de prueba (reports/churn_confusion_matrix.png).

Tablas de resultados numéricas detalladas: reports/svm_cv_results.csv (LAB01) y reports/churn_svm_results.csv (LAB02).

Conclusión

Los dos desarrollos comparten el mismo esqueleto metodológico —partición estratificada, un baseline Dummy como piso de comparación, y un SVM dentro de un Pipeline— pero cuentan historias distintas sobre qué significa “un buen modelo”. En LAB01, el salto de F1 macro de 0.38 a 0.98 es enorme porque el dataset de cáncer de mama es linealmente muy separable: es un problema casi de manual para SVM, y el ajuste con GridSearchCV apenas mueve la aguja (0.974 en validación cruzada), lo cual en sí mismo es una señal de que el modelo ya estaba cerca de su techo antes de tunear nada.

LAB02 es el caso más interesante para mí, precisamente porque el dataset no es de juguete: lo elegí, audité y documenté yo mismo, incluyendo un error propio que corregí en el camino (una fuente de terceros que traía columnas inventadas que no existen en el archivo oficial de UCI). Ahí el salto de 0.457 a 0.841 en F1 macro también es grande, pero el número que más me importa no es ese promedio: es que el recall de la clase Churn=1 es apenas 0.58. Eso significa que, de cada 10 clientes que realmente se van a ir, el modelo solo detecta a 6. Y ese es exactamente el error que definí como más costoso en la ficha del dataset antes de entrenar nada: un falso negativo es un cliente que se pierde sin que el equipo de retención tenga oportunidad de intervenir.

Esta diferencia entre los dos desarrollos me deja una conclusión que va más allá de cualquiera de los dos datasets: un F1 macro alto no dice nada sobre si el modelo sirve para la decisión de negocio que se supone que debe apoyar. En LAB01 esa pregunta no aplicaba (es un ejercicio ilustrativo, no clínico, como aclara el propio notebook). Pero en LAB02, donde sí definí una decisión real —a quién contactar antes de que se vaya—, un accuracy de 93% y un F1 macro de 0.84 pueden esconder que casi la mitad de los clientes que se van pasan desapercibidos. La siguiente iteración razonable no es perseguir un F1 macro más alto en el grid search, sino priorizar explícitamente el recall de la clase de interés, por ejemplo con `class_weight="balanced"` o moviendo el umbral de decisión sobre `predict_proba`, y volver a evaluar con esa prioridad de negocio en mente desde el inicio, no como una corrección posterior.